Московский Государственный Университет им. М.В. Ломоносова
Факультет Вычислительной Математики и Кибернетики
Кафедра Суперкомпьютеров и Квантовой Информатики

Практикум на ЭВМ: 7 семестр.

Отчёт № 2.

Анализ улучшений программы на CUDA, реализующей свертку изображения

Работу выполнил

Федоров В. В.

Москва 2021

Постановка задачи и формат данных.

Задача: Реализовать улучшения программы с использованием CUDA, осуществляющей свертку изображения с тремя заранее выбранными ядрами (2 ядра 3x3 и 1 ядро 5x5), протестировать программу в двух режимах – на большом изображении размером минимум 2000x2000 и на множестве малых изображений размером порядка 300x300.

Математическое описание

В общем виде свертка является операцией над произвольной матрицей A размеров $N \times M$ и другой матрицей K размера $2p+1 \times 2q+1$, называемой ядром свертки. Выходом этой операции является матрица B, вычисляемая по следующей формуле:

$$B[x][y] = \sum_{i=-p}^{p} \sum_{j=-q}^{q} A[x+i][y+j] \times K[i][j]$$

Для простоты элементы ядра нумеруем, начиная с $(-p, -q)$. Для того, чтобы не выходить за границу входного массива, размер выходного массива получается равным $N-2p \times M-2q$. В случае изображения оно представляется в виде нескольких матриц, каждая из которых сворачивается по отдельности. Для тестирования программы были выбраны следующие 3 ядра:

Увеличение резкости (Sharpen): $\begin{bmatrix} 0 & -1 & 0 \\ -1 & 5 & -1 \\ 0 & -1 & 0 \end{bmatrix}$

Обнаружение границ (Edge detection): $\begin{bmatrix} -1 & -1 & -1 \\ -1 & 8 & -1 \\ -1 & -1 & -1 \end{bmatrix}$

Гауссово размытие (Gauss blur): $\frac{1}{256}\begin{bmatrix} 1 & 4 & 6 & 4 & 1 \\ 4 & 16 & 24 & 16 & 4 \\ 6 & 24 & 36 & 24 & 6 \\ 4 & 16 & 24 & 16 & 4 \\ 1 & 4 & 6 & 4 & 1 \end{bmatrix}$

Примеры работы свертки с данными ядрами:

Оригинал	Sharpen	Edge detection	Gauss blur
			

Описание программы

Программа состоит из следующих элементов:

- `__global__ void conv(Pixel *src, Pixel *tgt, double *ker, int ker_pad, int width, int height);` - функция, выполняемая CUDA-ядрами. Осуществляет свертку для одного пикселя выходного изображения.
- `class CudaProcessor;` - класс, хранящий в себе выделенные в оперативной памяти GPU массивы для входного и выходного изображения и для ядра, а также некоторые числовые параметры вроде размеров изображений и замеров по времени. Он имеет следующие методы:

    - `CudaProcessor(int width, int height, double* convker, int _ker_dim);` - выделяет необходимую память на GPU.
    - `void ProcessImage(Image& input, Image& output);` - обрабатывает входное изображение и сохраняет результат в выходное.
    - `~CudaProcessor();` - освобождает выделенную память.
- `int main(int argc, char *argv[]);` - основной цикл работы программы, открывает изображения, обрабатывает их и сохраняет, после чего выводит замер времени.

Программа написана с использованием CMake и библиотеки STB для открытия и сохранения изображений. После сборки из папки bin необходимо запустить программу при помощи команды `./main <sharpen/edge/gauss5> <large/small>`
В случае аргумента large программа обрабатывает 1 изображение размером 5000x5000, в случае small – 1000 изображений размером 300x300.
Были реализованы следующие улучшения:

1. Использование отдельных функций для каждого фильтра вместо единой функции для всех.
2. Переиспользование динамической памяти, выделяемой библиотекой STB для открытия изображений. Вместо того, чтобы для каждого изображения выделять память заново и затем освобождать ее, программа сохраняет выделенную память и затем использует ее для новых изображений.
3. Для реализации параллельной обработки на девайсе копирования данных между процессором и девайсом каждое изображение обрабатывается в своем CUDA-потоке.
4. Была добавлена возможность загружать и обрабатывать N изображений за раз. Тестирование было проведено при N = 100.
5. После открытия изображения оно разделяется на 4 массива, в каждом из которых хранится отдельный канал, после чего каждый канал обрабатывается отдельно в своем CUDA-потоке.
6. Функции были переписаны с использованием разделяемой памяти: каждой нити соответствует пиксель из входного изображения и ячейка в разделяемой памяти, в которую она его копирует. После копирований нити синхронизируются и считают свертку на основе данных из разделяемой памяти.

Тестирование и результаты

Программа запускалась на системе Polus. Тестирование показало следующие результаты по времени:

Wall-time работы программы, с

Ядро свертки	Режим работы	Оригинал	1	2	3	4	5	6
Sharpen	Large	33.781229	31.100689	30.873911	31.644489	31.551375	32.005761	30.854136
	Small	191.530448	180.008894	175.198975	178.124867	174.862174	175.701360	178.038064
Edge	Large	32.126672	31.040447	30.803197	31.903159	31.548928	32.905156	30.706696
	Small	185.065419	181.572233	178.714117	176.291504	166.736041	167.609524	165.744487

Gauss 5	Large	31.684950	30.915566	30.819251	31.108766	31.192464	31.714750	30.515474
	Small	177.057809	168.251438	167.364230	167.373238	166.464592	167.805969	166.419692

Число обработанных пикселей / с

Ядро свертки	Режим работы	Оригинал	1	2	3	4	5	6
Sharpen	Large	740056	803841	809745	743064	768017	781109	784827
	Small	469899	499975	513702	505264	514691	512233	505510
Edge	Large	778170	805401	811604	759805	768074	759759	759724
	Small	486315	495671	503598	510518	539775	536962	543004
Gauss5	Large	789018	808654	811181	830323	828021	813941	847013
	Small	508309	534914	537749	537720	540656	536334	540801

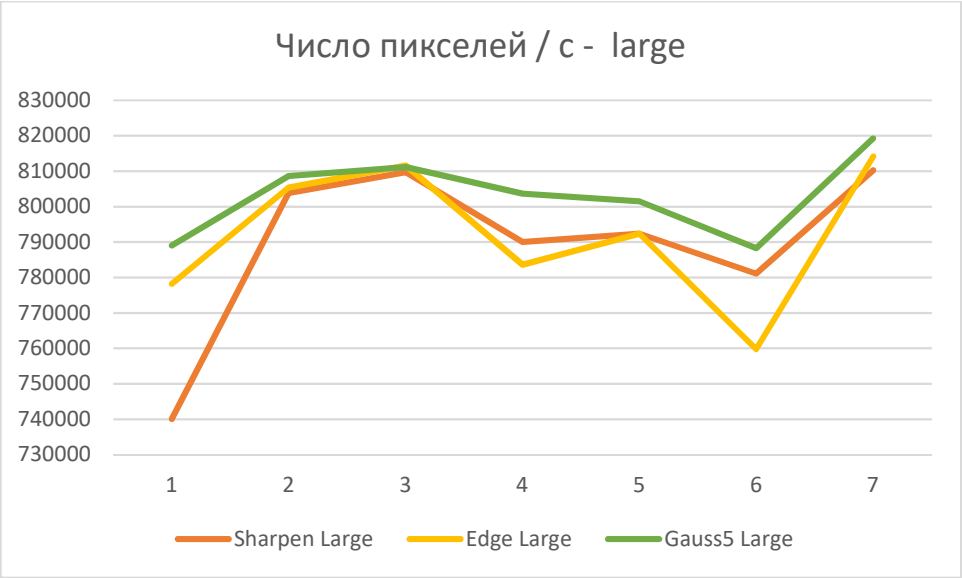

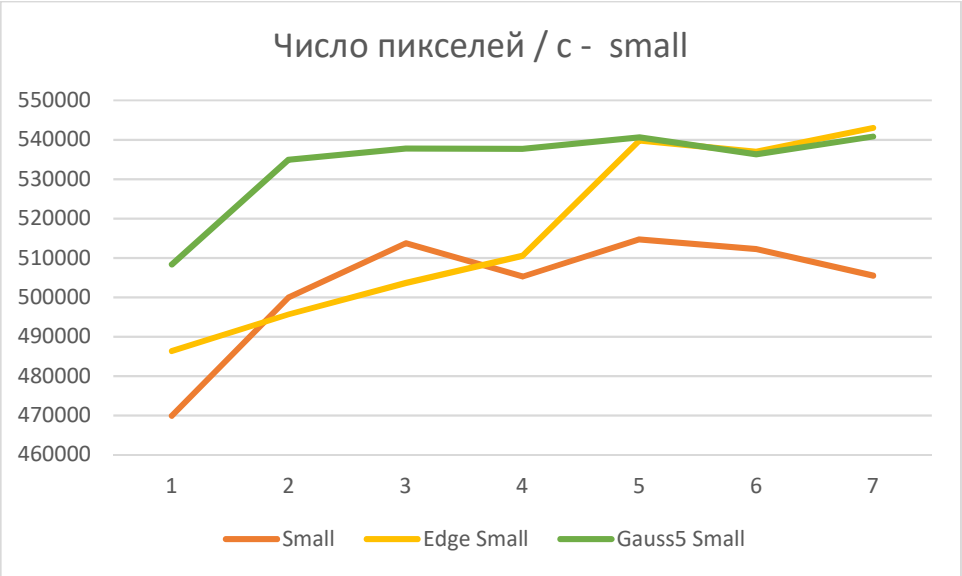

Основные выводы.

В силу того, что большую часть времени программа тратит на открытие изображений с диска, ускорение работы GPU не дало значительных результатов. Использование индивидуальных ядровых функций для каждой свертки однозначно улучшило программу, действие остальных улучшений оказалось сомнительным.